

**ПРАКТИЧЕСКОЕ ЗАДАНИЕ 3 по курсу "Методы оптимизации в
машинном обучении".
Метод барьеров.**

Выполнила студентка группы 191,
Косовская Арина

Содержание

1	Введение	2
2	Теоретическая часть	2
2.1	Вспомогательная функция	3
2.2	Система линейных уравнений, задающая ньютоновское направление	3
2.3	Решение системы	4
2.4	Максимально допустимая длина шага	4
2.5	Выбор начальной точки	5
3	Эксперименты	5
3.1	Эксперимент а	5
3.2	Эксперимент б	6

1 Введение

Данное задание посвящено методу барьеров — методу решения условных задач оптимизации с ограничениями вида неравенств:

$$\min_x f(x) \text{ s.t. } g_i(x) \leq 0, \quad i = 1, \dots, m,$$

где $f, g_1, \dots, g_m \in \mathbb{R}^n \rightarrow \mathbb{R}$ — дважды непрерывно дифференцируемые функции, $x \in \mathbb{R}^n$ — целевая переменная.

Для решения вспомогательной задачи $f_t(x) := t \cdot f(x) + F(x)$, где $\forall t \geq 0$ $f_t : \text{int } Q \rightarrow \mathbb{R}$, $Q := \{x \in \mathbb{R}^n : g_i(x) \leq 0 \forall i = 1, \dots, m\}$, $F : \text{int } Q \rightarrow \mathbb{R}$ в данном задании будем пользоваться метод Ньютона. В качестве критерия останова используется $\|\nabla f_{t_k}(y_l)\|_2^2 \leq \varepsilon_{\text{inner}} \|\nabla f_{t_k}(x_k)\|_2^2$, где $\varepsilon_{\text{inner}} > 0$ — некоторый параметр. Также будет рассматриваться логарифмический барьер $F(x) := -\sum_{i=1}^m \ln(-g_i(x))$.

В схеме отслеживания пути будет использоваться линейное увеличение параметров t_k : $t_{k+1} = \gamma t_k$, где $\gamma > 1$ — постоянная константа.

Для решения оптимизационной задачи $\phi(x) := \frac{1}{2} \sum_{i=1}^m (\langle a_i, x \rangle - b_i)^2 + \lambda \sum_{j=1}^n |x_j| := \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}$ будет использоваться критерий останова $\eta(x, \mu(x)) < \varepsilon$, где $\eta(x, \mu(x))$ — зазор двойственности.

В данном задании будет реализована процедура вычисления зазора двойственности и реализован метод барьеров. Для решения гладкой условной задачи $\min_{x,u} \left\{ \frac{1}{2} \|Ax - b\|_2^2 + \lambda \langle 1_n, u \rangle \right\} \text{ s.t. } x \preceq u, \quad x \succeq -u$ найдена вспомогательная функция, выписана система линейных уравнений, задающая ньютоновское направление d_k , а также предложен способ ее решения. Для точки (x, u) и направления d_k определена максимально допустимая длина шага α . Проведены соответствующие эксперименты.

2 Теоретическая часть

Рассмотрим гладкую условную задачу

$$\min_{x,u} \left\{ \frac{1}{2} \|Ax - b\|_2^2 + \lambda \langle 1_n, u \rangle \right\} \text{ s.t. } x \preceq u, \quad x \succeq -u, \text{ где } x, u \in \mathbb{R}^n, \\ 1_n = (1, \dots, 1) \in \mathbb{R}^n. \text{ Будем решать ее методом барьеров.}$$

Перепишем ограничения. Из условия $\begin{cases} x - u \preceq 0 \\ x + u \preceq 0 \end{cases} \Rightarrow \begin{cases} x - u \preceq 0 \\ -x - u \preceq 0 \end{cases}$

Пусть $g_1(x, u) := x - u$, $g_2(x, u) = -x - u$. Также определим $g_{1i} = x_i - u_i$, $g_{2i} = -x_i - u_i$.

Тогда множество, задаваемое функциональными ограничениями:

$$Q := \{x, u \in \mathbb{R}^n : g_{1i} \leq 0, g_{2i} \leq 0 \forall i = 1, \dots, n\}.$$

2.1 Вспомогательная функция

Пусть $F : \text{int } Q \rightarrow \mathbb{R}$ — логарифмическая барьерная функция, тогда $\forall t$ определим вспомогательную функцию $f_t : \text{int } Q \rightarrow \mathbb{R}$ как $t \cdot f(x) + F(x)$.

$$\begin{aligned} F(x, u) &= - \sum_{i=1}^n (\ln(-g_{1i}(x, u)) + \ln(-g_{2i}(x, u))) = - \sum_{i=1}^n \ln(u_i - x_i) - \sum_{i=1}^n \ln(x_i + u_i) = \\ &= -\langle 1_n, \ln(u - x) \rangle - \langle 1_n, \ln(x + u) \rangle. \end{aligned}$$

$$f_t(x, u) = t \cdot \left(\frac{1}{2} \|Ax - b\|_2^2 + \lambda \langle 1_n, u \rangle \right) - \langle 1_n, \ln(u - x) \rangle - \langle 1_n, \ln(x + u) \rangle.$$

Перейдем к решению вспомогательной задачи. В качестве алгоритма минимизации будем использовать метод Ньютона.

2.2 Система линейных уравнений, задающая ньютоновское направление

Пусть $d_k = (d_k^x, d_k^u)$ — Ньютоновское направление. Вспомним, что оно задается с помощью уравнения $\nabla^2 f_t(x_k, u_k) d_k = -\nabla f_t(x_k, u_k)$.

Далее будем обозначать f'_{tx} — частную производную f_t по аргументу x , f''_{txx} — частную производную второго порядка от f'_{tx} по аргументу x .

$$\begin{aligned} \nabla f_t &= \begin{pmatrix} f'_{tx} \\ f'_{tu} \end{pmatrix} = \begin{pmatrix} tA^T(Ax - b) + \frac{1}{u-x} - \frac{1}{x+u} \\ t\lambda 1_n - \frac{1}{u-x} + \frac{1}{x+u} \end{pmatrix} \\ \nabla^2 f_t &= \begin{pmatrix} f''_{txx} & f''_{txu} \\ f''_{tux} & f''_{tuu} \end{pmatrix} = \\ &= \begin{pmatrix} tA^T A + \text{diag}\left(\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right) & \text{diag}\left(-\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right) \\ \text{diag}\left(-\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right) & \text{diag}\left(\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right) \end{pmatrix} \end{aligned}$$

Тогда получается следующая система уравнений:

$$\begin{pmatrix} tA^T A + \text{diag}\left(\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right) & \text{diag}\left(-\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right) \\ \text{diag}\left(-\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right) & \text{diag}\left(\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right) \end{pmatrix} \begin{pmatrix} d^x \\ d^u \end{pmatrix} = \\
= \begin{pmatrix} tA^T(Ax - b) + \frac{1}{u-x} - \frac{1}{x+u} \\ t\lambda 1_n - \frac{1}{u-x} + \frac{1}{x+u} \end{pmatrix} \\
\begin{cases} [tA^T A + \text{diag}\left(\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right)] d^x + [\text{diag}\left(-\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right)] d^u = \\ = -tA^T(Ax - b) - \frac{1}{u-x} + \frac{1}{x+u} \\ [\text{diag}\left(-\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right)] d^x + [\text{diag}\left(\frac{1}{u-x} \odot \frac{1}{u-x} + \frac{1}{x+u} \odot \frac{1}{x+u}\right)] d^u = \\ = -t\lambda 1_n + \frac{1}{u-x} - \frac{1}{x+u} \end{cases}$$

2.3 Решение системы

Для решения системы воспользуемся разложением Холецкого. Как обсуждалось на лекции, это устойчивая и быстрая операция. По сравнению с решением системы уравнений в лоб, время, требуемое на выполнение задачи, уменьшится. Тем не менее, все еще приходится вычислять $A^T A$, что, как известно, затратно по времени.

Для уменьшения затрат по памяти можно выразить d^u из первого уравнения и подставить во второе. Тогда можно решить второе уравнение вновь с помощью разложения Холецкого, а после подставить найденное d^x в первое уравнение и найти d^u . Размерность уменьшится вдвое.

2.4 Максимально допустимая длина шага

Заметим, что функции g_1, g_2 , соответствующие условиям задачи, являются

$$\begin{aligned} & \text{аффинными. Действительно, } g_1 = x - u = \left\langle \begin{pmatrix} 1_n \\ -1_n \end{pmatrix}, x \right\rangle - 0_n^T, \quad g_2 = -x - u = \\ & = \left\langle \begin{pmatrix} -1_n \\ -1_n \end{pmatrix}, x \right\rangle - 0_n^T. \text{ То есть } q_1 = \begin{pmatrix} 1_n \\ -1_n \end{pmatrix}, \quad s_1 = s_2 = 0_n^T, \quad q_2 = \begin{pmatrix} -1_n \\ -1_n \end{pmatrix}. \end{aligned}$$

Тогда, согласно теории, $\alpha_l^{\max} = \min_{i \in I_l} -\frac{\langle q_i, y_l \rangle}{\langle q_i, d_l \rangle}$.

Для подбора длины шага используется процедура бэктрекинга, а для решения вспомогательной задачи используется метод Ньютона.

Пусть $I_l = \{\langle q_1, d_l \rangle > 0, \langle q_2, d_l \rangle > 0\}$. Так длина шага должна быть положительной и не превосходить 1, учитывая условие выше, получим:

$$\alpha_l^{\max} = \min \left\{ 1, \theta \min_{i=1 \dots n, d_{li}^x - d_{li}^u > 0} \frac{u_{li} - x_{li}}{d_{li}^x - d_{li}^u}, \theta \min_{i=1 \dots n, -d_{li}^x - d_{li}^u > 0} \frac{u_{li} + x_{li}}{-d_{li}^x - d_{li}^u} \right\}$$

В качестве θ выберем 0.99.

2.5 Выбор начальной точки

Так как начальная точка должна лежать внутри множества Q , выберем точку $\begin{pmatrix} 1_n \\ 2 \\ 1_n \end{pmatrix}$.

3 Эксперименты

3.1 Эксперимент а

. Исследуем чувствительность реализованного метода барьеров для задачи LASSO к выбору параметров γ (скорость увеличения t_k) и ϵ_{inner} (точность для метода Ньютона).

Первым рассмотрим эксперимент, когда исследовалась чувствительность метода к выбору γ . Остальные параметры были выбраны по умолчанию. Для этого был взят набор данных w8a, имеющий размерность (49749, 300). Результаты эксперимента изображены на рисунке 3.1.

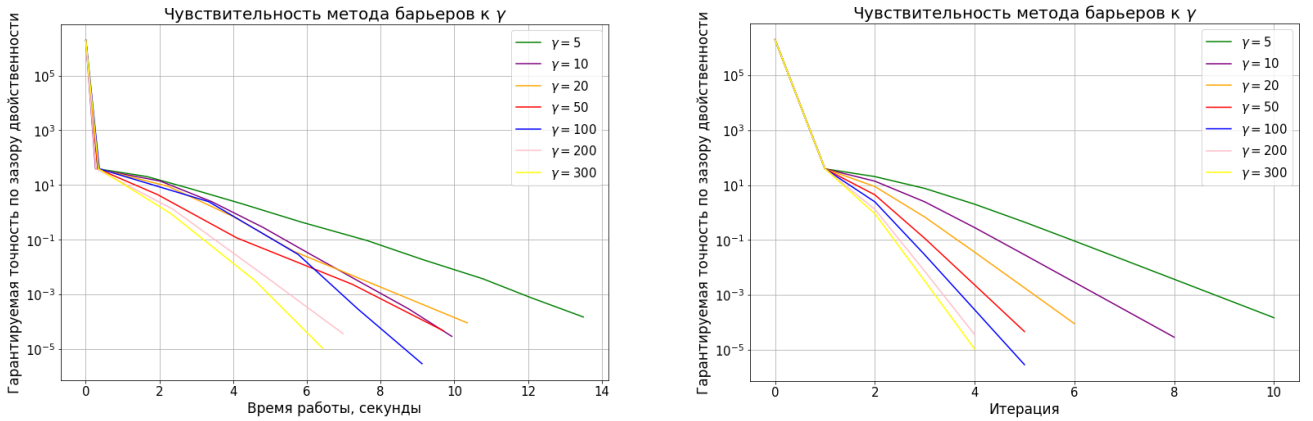


Рис. 3.1: Чувствительность метода барьеров к γ .

Заметим, что чем больше γ , тем меньше время работы и тем меньше зазор двойственности. Для больших γ требуется меньшее число итераций для получения высокой гарантированной точности. Тем не менее, все $\gamma \in [10; 300]$ работают за приблизительно одинаковые время и количество итераций, а для $\gamma = 5$ метод работает хуже. Можно сделать предположение, что γ должна выбираться из этого промежутка в зависимости от других параметров.

Вывод: увеличение γ приводит к уменьшению времени работы и уменьшению числа итераций до сходимости.

Теперь проведем эксперимент, в котором исследуется чувствительность метода барьеров к значению ϵ_{inner} . Вновь остальные параметры были выбраны по умолчанию, использовался набор данных w8a. Результаты представлены на рисунке 3.2.




Рис. 3.2: Чувствительность метода барьеров к ϵ_{inner}

Видим, что значение ϵ_{inner} не влияет на количество итераций до сходимости, за исключением наибольшего $\epsilon_{\text{inner}} = 0.1$. При этом же значении параметра достигается наименьшее время работы метода. В целом, чем больше ϵ_{inner} , тем меньше времени требовалось для работы метода барьеров. То есть чем меньше значение ϵ_{inner} , тем дольше совершается итерация (что обусловлено дольшей работой метода Ньютона). Также заметим, что выбор ϵ_{inner} не влияет на гарантированную точность по зазору двойственности.

Вывод: для высокой точности и быстрой работы метода достаточно выбрать $\epsilon_{\text{inner}} = 0.1$. При дальнейшем уменьшении ϵ_{inner} на каждую итерацию будет требоваться больше времени, гарантированная точность при этом не меняется.

3.2 Эксперимент б

Перейдем к исследованию поведения метода для различных значений размерности пространства n , размера выборки m и коэффициента регуляризации λ .

Первым проведем эксперимент с размерностью пространства. Для этого сгенерируем случайные A и b так, чтобы размерность пространства была n , m выбралось равным 100. Остальные параметры выбраны по умолчанию. Результаты представлены на рисунке 3.3.




Рис. 3.3: Поведение метода для различных значений размерности пространства n .

При небольших значениях n (не превосходящих 100) метод работает одинаково быстро. При дальнейшем увеличении размерности пространства метод начинает работать дольше, что объяснимо сложностью итерации метода Ньютона и используемой в нем стратегии подбора длины шага. При этом методу требуется приблизительно одинаковое число итераций для различных значений n , что еще раз подтверждает, что при увеличении размерности пространства увеличивается время выполнения итерации метода барьеров, то есть время работы метода Ньютона.

Вывод: с увеличением размерности пространства увеличивается время выполнения одной итерации метода барьеров.

Теперь рассмотрим поведение метода при изменении размера выборки m . Вновь были сгенерированы случайные A и b соответствующих размеров, остальные параметры были выбраны по умолчанию. $n = 100$. Результаты представлены на рисунке 3.4.




Рис. 3.4: Поведение метода для различных значений размера выборки m .

Число итераций от сходимости не зависит от размера выборки. Явной зави-

симости времени работы метода от размера выборки при $m \leq 5000$ также не наблюдается. При $m = 50000$ время работы увеличивается до 6 секунд. Объяснить это можно тем, что стоимость вычисления матриц $Ax - b$, $A^T(Ax - b)$ составляет $O(m * n)$, а метод Ньютона "стоит" $O(n^3)$. Поэтому при увеличении n время выполнения одной итерации метода барьеров сильно увеличивается, а при увеличении m — нет (только при очень больших значениях m будет более явно наблюдаться линейная зависимость).

Вывод: при размерах выборки, меньших 5000, время работы метода одинаковое. При дальнейшем увеличении m время работы метода будет расти значительно.

Наконец, исследуем поведение метода в зависимости от коэффициента регуляризации. В качестве данных использовался набор w8a. Остальные значения выбраны по умолчанию. Результаты представлены на рисунке 3.5.




Рис. 3.5: Поведение метода для различных значений коэффициента регуляризации λ .

Вывод: значение коэффициента регуляризации не влияет на число итераций. При увеличении λ немного увеличивается время работы метода.